

Rapport

Yohann BOGAERT - Killian Damasceno

Analyse distribuée des accidents de la route aux États-Unis

1. Introduction

Les accidents de la route constituent un enjeu majeur de sécurité publique et génèrent chaque année des volumes importants de données. L'analyse de ces données permet d'identifier des tendances spatiales et temporelles, d'évaluer les facteurs de gravité et d'améliorer la prévention routière.

L'objectif de ce projet est de mettre en pratique les concepts et technologies de la plateforme Hadoop à travers l'analyse d'un jeu de données réel et volumineux portant sur les accidents de la route aux États-Unis. Le projet repose sur une architecture distribuée et exploite les principales briques de l'écosystème Hadoop : HDFS, YARN, MapReduce et Hive.

2. Présentation du jeu de données

Le jeu de données utilisé est **US Accidents**, disponible sur la plateforme Kaggle.

Il contient plusieurs millions d'enregistrements d'accidents survenus aux États-Unis entre 2016 et 2023.

Chaque enregistrement décrit un accident à l'aide de nombreuses variables, parmi lesquelles :

- la localisation géographique (État, ville, latitude, longitude),
- la date et l'heure de début de l'accident,
- la gravité de l'accident,
- les conditions météorologiques,
- des informations sur l'environnement routier.

Le volume du fichier (~ 3.6 Go) rend ce jeu de données particulièrement adapté à une approche distribuée avec Hadoop.

3. Architecture et technologies utilisées

Le projet a été réalisé sur un cluster Hadoop virtualisé à l'aide d'une machine virtuelle Cloudera.

Les technologies utilisées sont :

- **HDFS** : stockage distribué du fichier de données,
- **YARN** : gestion des ressources et ordonnancement des traitements,
- **MapReduce** : traitement distribué des données,
- **Hive** : analyse analytique via des requêtes SQL distribuées.

Cette architecture permet de traiter efficacement un volume de données important tout en assurant la scalabilité des traitements.

4. Développement de l'architecture distribuée (Partie MapReduce)

Cette partie présente les différents traitements MapReduce mis en œuvre afin d'analyser le jeu de données US Accidents de manière distribuée. Cinq jobs MapReduce ont été développés, chacun

répondant à une problématique spécifique d'analyse spatiale, temporelle ou contextuelle.

4.1 Stockage des données dans HDFS

Le fichier `USA.csv` a été importé dans le système de fichiers distribués HDFS.

Il est stocké dans le répertoire suivant :

```
/user/cloudera/us_accidents/input/USA.csv
```

Ce stockage distribué permet à Hadoop de découper automatiquement le fichier en blocs et de paralléliser les traitements.

HDFS découpe automatiquement le fichier en blocs, permettant l'exécution parallèle des traitements MapReduce sur l'ensemble du cluster Hadoop.

4.2 Job MapReduce 1 : Nombre d'accidents par État

Le premier job MapReduce calcule le nombre total d'accidents pour chaque État américain.

- **Mapper** : extrait la colonne `State` et émet des paires clé-valeur de la forme `(State, 1)`.
- **Reducer** : agrège les valeurs associées à chaque État afin de calculer le nombre total d'accidents.

Ce traitement permet d'identifier les États les plus accidentogènes et de mettre en évidence des disparités géographiques.

```
Total MapReduce CPU Time Spent: 3 minutes 27 seconds 450 msec
OK
CA      1741433
FL      880192
TX      582837
SC      382557
NY      347960
NC      338199
VA      303301
PA      296620
MN      192084
OR      179660
AZ      170609
GA      169234
IL      160958
TN      167388
MI      162191
LA      149701
NJ      140719
MD      140417
OH      118115
WA      108221
Time taken: 254.834 seconds, Fetched: 20 row(s)
```

4.3 Job MapReduce 2 : Gravité moyenne par État

Le second job MapReduce calcule la gravité moyenne des accidents par État.

- **Mapper** : extrait les colonnes `State` et `Severity` et émet des paires `(State, Severity)`.
- **Reducer** : calcule la moyenne de la gravité pour chaque État en agrégeant les valeurs reçues.

Ce traitement permet de comparer la sévérité moyenne des accidents selon les régions, indépendamment du volume total d'accidents.

```
Total MapReduce CPU Time Spent: 4 minutes 4 seconds 550 msec
OK
GA      2.51
WI      2.47
RI      2.46
KY      2.45
CO      2.44
SD      2.44
VT      2.43
IA      2.42
IN      2.4
MO      2.4
IL      2.38
NM      2.37
CT      2.35
OH      2.35
WA      2.34
MI      2.34
MS      2.34
WY      2.34
KS      2.33
MD      2.33
Time taken: 280.47 seconds, Fetched: 20 row(s)
```

4.4 Job MapReduce 3 : Nombre d'accidents par mois

Ce job MapReduce vise à analyser l'évolution temporelle des accidents.

- **Mapper** : extrait la date de début de l'accident (`StartTime`), conserve le format `YYYY-MM` et émet des paires `(Mois, 1)` .
- **Reducer** : somme les valeurs afin de calculer le nombre d'accidents pour chaque mois.

Ce traitement permet d'observer des tendances saisonnières et des variations temporelles dans la fréquence des accidents.

```
2021-01 152914
2021-02 154935
2021-03 90643
2021-04 90888
2021-05 101732
2021-06 131472
2021-07 113333
2021-08 120868
2021-09 134874
2021-10 134287
2021-11 157729
2021-12 180078
2022-01 135900
2022-02 163839
2022-03 140145
2022-04 196687
2022-05 159566
2022-06 129264
2022-07 140672
2022-08 152361
2022-09 139016
2022-10 85135
2022-11 130959
2022-12 180908
2023-01 160914
2023-02 55532
2023-03 30187
Time taken: 213.649 seconds, Fetched: 87 row(s)
```

4.5 Job MapReduce 4 : Nombre d'accidents par condition météorologique

Ce quatrième job MapReduce analyse l'impact des conditions météorologiques sur la fréquence des accidents.

- **Mapper** : extrait la colonne `Weather_Condition` et émet des paires `(Condition_météo, 1)` .
- **Reducer** : agrège les valeurs afin de calculer le nombre total d'accidents pour chaque condition météorologique.

Ce traitement permet d'identifier les conditions météorologiques les plus fréquemment associées aux accidents de la route.

```
Total MapReduce CPU Time Spent: 4 minutes 2 seconds 0 msec
OK
Fair      2560802
Mostly Cloudy  1016195
Cloudy      817082
Clear       808743
Partly Cloudy  698972
Overcast     382866
Light Rain   352957
Scattered Clouds  204829
Light Snow   128680
Fog          99238
Rain         84331
Haze         76223
Fair / Windy  35671
Heavy Rain   32309
Light Drizzle 22684
Thunder in the Vicinity 17611
Cloudy / Windy 17035
T-Storm 16810
Mostly Cloudy / Windy 16508
Snow        15537
Time taken: 273.64 seconds, Fetched: 20 row(s)
```

4.6 Job MapReduce 5 : Gravité moyenne par condition météorologique

Le dernier job MapReduce calcule la gravité moyenne des accidents en fonction des conditions météorologiques.

- **Mapper** : extrait les colonnes `Weather_Condition` et `Severity` et émet des paires `(Condition_météo, Severity)`.
- **Reducer** : calcule la gravité moyenne des accidents pour chaque condition météorologique.

Ce traitement permet d'évaluer si certaines conditions météorologiques sont associées à des accidents plus graves que d'autres.

```
Total MapReduce CPU Time Spent: 3 minutes 50 seconds 310 msec
OK
Thunderstorms and Rain  2.46    2217
Heavy Thunderstorms and Rain  2.46    2485
Light Thunderstorms and Rain  2.44    4931
Thunderstorm  2.41    4438
Light Freezing Rain  2.4    3465
Light Freezing Fog  2.39    1001
Overcast  2.39    382866
Scattered Clouds  2.38    204829
Clear  2.37    808743
Light Freezing Drizzle  2.36    1240
Drizzle 2.3    4726
Light Drizzle  2.27    22684
Rain  2.26    84331
Heavy Rain  2.26    32309
Mist  2.26    3539
Light Rain  2.25    352957
Light Snow  2.25    128680
Snow  2.25    15537
Heavy Snow  2.24    5003
Partly Cloudy  2.22    698972
Time taken: 275.97 seconds, Fetched: 20 row(s)
```

4.7 Synthèse des traitements MapReduce

L'ensemble des cinq jobs MapReduce permet de couvrir différentes dimensions de l'analyse des accidents de la route :

- une analyse **spatiale** (par État),
- une analyse **temporelle** (par mois),
- une analyse **contextuelle** (conditions météorologiques),

- une analyse **quantitative** (fréquence),
- une analyse **qualitative** (gravité).

Ces traitements démontrent la flexibilité et la pertinence du modèle MapReduce pour le traitement distribué de données massives.

5. Analyse des données avec Hive

5.1 Création de la table Hive

Une table externe Hive a été créée sur le fichier stocké dans HDFS.

L'utilisation de `OpenCSVSerde` permet de gérer correctement les champs contenant des virgules ou des guillemets.

La table `accidents_raw` est associée à la base de données `us_accidents`.

```
hive> USE us_accidents;
OK
Time taken: 0.948 seconds
hive> SHOW TABLES;
OK
accidents_raw
```

```
hive> SELECT *
> FROM accidents_raw
> LIMIT 5;
OK
A-1 Source2 3 2016-02-08 05:46:00 2016-02-08 11:00:00 39.865147 -84.058723 0.01R
ight lane blocked due to accident on I-70 Eastbound at Exit 41 OH-235 State Route 4, I-70 E Dayton Montgomery OH 4
5424 US US/Eastern KFO 2016-02-08 05:58:00 36.9 91.0 29.68 10.0 Calm 0.02L
ight Rain False False False False False False False False False False False False False False Night
Night Night Night
A-2 Source2 2 2016-02-08 06:07:59 2016-02-08 06:37:59 39.928059000000001 -82.831184 0 0
Accident on Brice Rd at Tussing Rd. Expect delays. Brice Rd Reynoldsburg Franklin OH 43668
-3402 US US/Eastern KOW 2016-02-08 05:51:00 37.9 100.0 29.05 10.0 Calm 0.0 L
ight Rain False False False False False False False False False False False False False False Night
Night Night Day
A-3 Source2 2 2016-02-08 06:49:27 2016-02-08 07:19:27 39.063148 -84.032608 0.01A
ccident on OH-32 State Route 32 Westbound at Dela Palma Rd. Expect delays. State Route 32 Williamsburg Clermont 0
H 45176 US US/Eastern KJ69 2016-02-08 06:56:00 36.0 33.3 100.0 29.67 10.0 SW 3.5 0
vercast False False False False False False False False False False True False Night Night
Day Day
A-4 Source2 3 2016-02-08 07:23:34 2016-02-08 07:53:34 39.747753 -84.205581999999998 0
Accident on I-75 Southbound at Exits 52 52B US-35. Expect delays. I-75 S Dayton Montgomery OH 45417
US US/Eastern KDAY 2016-02-08 07:38:00 35.1 31.0 96.0 29.64 9.0 SW 4.6 Mostl
y Cloudy False False False False False False False False False False False False False Night
Day Day Day
```

5.2 Requêtes analytiques

Plusieurs requêtes analytiques ont été réalisées à l'aide de Hive :

- nombre d'accidents par État,
- gravité moyenne par État,
- évolution mensuelle du nombre d'accidents,
- analyse des conditions météorologiques les plus fréquentes.

Ces requêtes permettent d'explorer les données de manière plus flexible que MapReduce, grâce à l'utilisation de SQL distribué.

```
hive> [cloudera@quickstart mr]$ hdfs dfs -ls /user/cloudera/us_accidents/hive_results
Found 3 items
drwxr-xr-x - cloudera cloudera 0 2025-12-29 04:06 /user/cloudera/us_accidents/hive_results/monthly_counts
drwxr-xr-x - cloudera cloudera 0 2025-12-29 03:47 /user/cloudera/us_accidents/hive_results/state_counts
drwxr-xr-x - cloudera cloudera 0 2025-12-29 03:57 /user/cloudera/us_accidents/hive_results/state_severity_avg
```

5.3 Export des résultats

Certains résultats ont été exportés depuis Hive vers HDFS à l'aide de la commande `INSERT OVERWRITE DIRECTORY`.

Ces exports facilitent la réutilisation des résultats et leur visualisation.

```

[cloudera@quickstart mr]$ hdfs dfs -cat /user/cloudera/us_accidents/hive_results/state_severity_avg/* | head -n 20
GA 2.51
MT 2.47
RI 2.46
KY 2.45
CO 2.44
SD 2.44
VT 2.43
IA 2.42
IN 2.4
MO 2.4
IL 2.38
NM 2.37
CT 2.35
OH 2.35
WA 2.34
MI 2.34
MS 2.34
NY 2.34
KS 2.33
MD 2.33
-

[cloudera@quickstart mr]$ hdfs dfs -cat /user/cloudera/us_accidents/hive_results/monthly_counts/* | head -n 20
2016-01 7
2016-02 985
2016-03 6330
2016-04 18088
2016-05 17610
2016-06 30538
2016-07 45708
2016-08 56457
2016-09 54698
2016-10 55609
2016-11 65040
2016-12 59619
2017-01 55713
2017-02 51679
2017-03 57315
2017-04 48115
2017-05 41136
2017-06 46272
2017-07 43262
2017-08 80955

```

6. Tests et validation

Les traitements ont été testés progressivement :

- tests locaux des scripts MapReduce avant exécution distribuée,
- validation des résultats Hive à l'aide de requêtes avec `LIMIT`,
- comparaison des résultats Hive avec ceux obtenus via MapReduce.

Les résultats obtenus sont cohérents entre les différentes approches, ce qui valide la fiabilité des traitements.

7. Difficultés rencontrées et solutions apportées

Plusieurs difficultés ont été rencontrées au cours du projet :

- gestion d'un fichier CSV volumineux contenant des champs complexes,
- configuration de YARN et du NodeManager dans un environnement virtualisé,
- compatibilité des scripts avec des machines différentes (Python 2 et 3).

Ces problèmes ont été résolus par l'adaptation des scripts, l'optimisation des paramètres Hadoop et l'utilisation d'outils adaptés comme `OpenCSVSerde`.

8. Conclusion

Ce projet a permis de mettre en œuvre une application Hadoop complète, depuis le stockage distribué des données jusqu'à leur analyse. L'utilisation combinée de HDFS, MapReduce, YARN et Hive a démontré l'efficacité des architectures distribuées pour l'analyse de données massives.

Les jobs MapReduce ont permis de réaliser des calculs agrégés à grande échelle, tandis que Hive a apporté une couche analytique plus simple et plus lisible grâce à l'utilisation de requêtes SQL. Les résultats obtenus avec Hive se sont révélés cohérents avec ceux issus des traitements MapReduce.

Ce travail met en évidence la complémentarité des différentes briques de l'écosystème Hadoop. Des améliorations futures pourraient inclure l'utilisation de formats de stockage optimisés (ORC ou Parquet), la mise en place de partitions Hive ou l'utilisation de moteurs de calcul alternatifs comme Spark.

9. Liens vers les démos vidéos

partie 1:

<https://youtu.be/mMkFHraBnsI>

partie 2 :

https://youtu.be/_YJDAvzBbGo